



PRÉDICTION DE FAILLITE D'ENTREPRISE

Documentation Complète du Projet

Un système intelligent capable de détecter si une entreprise
risque de faire faillite — avec une précision de 97%

Caractéristique	Détail
Dataset utilisé	Entreprises polonaises (2000–2013)
Entreprises analysées	43 405 entreprises
Précision du système	97%
Technologie principale	Intelligence Artificielle (LightGBM)
Interface	Application Web Flask
Durée du projet	Mai–Juin 2026

1. Qu'est-ce que ce projet ?

1.1 Le problème résolu

Chaque année, des milliers d'entreprises font faillite sans que personne ne l'ait anticipé. Les banques, les investisseurs et les partenaires commerciaux se retrouvent pris au dépourvu, perdant parfois des sommes considérables.

■ *L'idée de ce projet : Et si une machine pouvait analyser les chiffres financiers d'une entreprise et dire, avant tout le monde, si elle risque de faire faillite ?*

C'est exactement ce que fait ce système. En analysant les données financières d'une entreprise, il peut prédire avec 97% de précision si cette entreprise est en bonne santé ou si elle court un risque de faillite.

1.2 À qui s'adresse ce système ?

- Les banques souhaitant évaluer le risque avant d'accorder un prêt
- Les investisseurs voulant protéger leur capital
- Les partenaires commerciaux souhaitant vérifier la solidité d'un client ou fournisseur
- Les dirigeants d'entreprise souhaitant détecter des signaux d'alarme en interne
- Les analystes financiers cherchant un outil d'aide à la décision

1.3 Comment ça fonctionne en résumé ?

On entre les chiffres financiers d'une entreprise → Le système les analyse en quelques secondes → Il affiche un score de risque (Faible / Modéré / Élevé) et explique pourquoi.

2. D'où viennent les données ?

2.1 La source

Le projet utilise le Polish Companies Bankruptcy Dataset, une base de données officielle provenant de l'Université de Californie (UCI Machine Learning Repository). Elle regroupe les données financières réelles d'entreprises polonaises sur une période de 13 ans, de 2000 à 2013.

2.2 Ce que contiennent les données

Pour chaque entreprise, le dataset contient 64 ratios financiers. Un ratio financier, c'est simplement une formule mathématique qui compare deux chiffres comptables pour mesurer la santé d'une entreprise.

Exemple simple : Si une entreprise gagne 100 000 € et doit 200 000 €, son ratio dette/revenu est 2. Un ratio élevé signifie que l'entreprise est très endettée — c'est un signal d'alarme.

2.3 Le volume de données

Type	Volume	Rôle
Données d'entraînement	33 613 entreprises	Pour apprendre
Données de test	9 792 entreprises	Pour évaluer
Total	43 405 entreprises	—
Ratios par entreprise	64 ratios	—
Part des faillites	~5%	Classe minoritaire

Les données sont divisées en deux groupes : un groupe pour apprendre (comme un étudiant qui étudie ses cours) et un groupe pour tester (comme l'examen final). Le système n'a jamais vu les données de test pendant l'apprentissage — c'est ce qui garantit que les résultats sont réels.

3. Préparation des données

Avant d'enseigner quoi que ce soit à la machine, il faut préparer les données — un peu comme préparer des ingrédients avant de cuisiner.

3.1 Renommage des variables

Les 64 ratios avaient des noms techniques comme Attr1, Attr2... jusqu'à Attr64. Chaque variable a été renommée avec son vrai nom financier pour rendre le projet lisible et compréhensible.

Attr1 → bénéfice net sur total actif
Attr7 → EBIT sur total actif
Attr27 → résultat exploitation sur charges financières

3.2 Gestion des valeurs manquantes

Dans le monde réel, certaines entreprises n'ont pas renseigné tous leurs chiffres. Plutôt que de les supprimer, le système remplace les valeurs manquantes par la valeur médiane des autres entreprises similaires. C'est une technique courante et fiable.

3.3 Mise à l'échelle des données

Certains ratios valent 0.001 et d'autres valent 1 000 000. Cette différence perturbe la machine. On utilise le RobustScaler qui ramène tous les chiffres sur une échelle comparable, sans être perturbé par les valeurs extrêmes.

Analogie : C'est comme convertir des distances — certaines en millimètres, d'autres en kilomètres — toutes en mètres pour pouvoir les comparer.

3.4 Rééquilibrage des classes (SMOTE)

Seulement 5% des entreprises ont fait faillite. Si on laisse le système apprendre avec ce déséquilibre, il dira que toutes les entreprises sont saines — et aura raison 95% du temps sans rien apprendre d'utile. La technique SMOTE crée des exemples artificiels supplémentaires d'entreprises en faillite pour équilibrer l'apprentissage à 50/50.

4. Exploration et analyse des données

Avant de construire le système, on a exploré les données pour mieux les comprendre — comme un médecin qui examine un patient avant de poser un diagnostic.

4.1 Ce qu'on a découvert

- Les entreprises en faillite ont en général un ratio d'endettement bien plus élevé
- La croissance du chiffre d'affaires d'une année sur l'autre est un signal fort
- Certaines valeurs sont extrêmement élevées (ex: ratio à 53 000 au lieu de 1-2) — identifiées et gérées
- Aucune donnée n'était manquante dans le dataset de base — une chance rare

4.2 Sélection des variables les plus importantes

Sur les 64 ratios disponibles, seulement 20 ont été retenus après analyse. Ces 20 variables sont celles qui ont le plus de pouvoir prédictif. Pour l'application finale, on a encore réduit à 10 variables — les plus décisives selon l'analyse SHAP.

5. Construction et comparaison des modèles

Un modèle d'intelligence artificielle apprend à partir d'exemples passés pour faire des prédictions sur de nouveaux cas. On a construit et comparé 6 modèles différents.

5.1 Les 6 modèles testés

Modèle	Description	Précision	Détection Faillite	Verdict
Régression Logistique	Modèle mathématique simple	56%	0.19	■ Écarté
Naive Bayes	Modèle probabiliste basique	64%	0.55	■ Écarté
AdaBoost	Ensemble de petits modèles	85%	0.83	■■ Moyen
Random Forest Rég.	Forêt d'arbres de décision	91%	0.92	■ Retenu
XGBoost Régularisé	Arbres boostés optimisés	96%	0.95	■ Retenu
LightGBM ■	Arbres boostés ultrarapides	97%	0.97	■ Meilleur

5.2 Pourquoi la précision seule ne suffit pas ?

En finance, rater une faillite (faux négatif) est bien plus grave que signaler une fausse alarme (faux positif). C'est pourquoi on mesure aussi le Recall — la capacité à détecter les vraies faillites. La Régression Logistique n'en détectait que 19% : éliminée.

5.3 Le problème de l'overfitting (surapprentissage)

L'overfitting, c'est quand un modèle mémorise les exemples d'entraînement au lieu d'apprendre des règles générales — comme un étudiant qui mémorise les réponses sans comprendre.

*XGBoost original : 100% sur entraînement → ■ Overfitting détecté
XGBoost régularisé : 97% entraînement / 96% test → ■ Résultat fiable*

6. Comprendre les décisions du système — SHAP

Un des grands défis de l'intelligence artificielle est la boîte noire : le modèle donne un résultat sans expliquer pourquoi. Ce projet résout ce problème avec la technologie SHAP.

6.1 Qu'est-ce que SHAP ?

SHAP décompose chaque prédiction et explique la contribution de chaque variable à la décision finale. C'est comme un relevé de compte qui détaille chaque dépense.

6.2 Les 10 variables les plus importantes

Rang	Variable financière	Ce qu'elle mesure
1 ■	Résultat exploitation / Charges financières	Capacité à rembourser ses dettes
2	Charges exploitation / Total dettes	Poids des charges vs dettes
3	Chiffre d'affaires N / N-1	Croissance ou déclin des ventes
4	Actif courant - Stocks / Dettes long terme	Liquidité face aux dettes longues
5	Chiffre d'affaires / Stocks	Vitesse de rotation des stocks
6	Dettes long terme / Capitaux propres	Niveau d'endettement à long terme
7	Chiffre d'affaires / Créances	Rapidité de recouvrement des créances
8	Bénéfices non distribués / Total actif	Réserves accumulées
9	Stocks x365 / Chiffre d'affaires	Durée de stockage des marchandises
10	Actif courant - Stocks / Dettes court terme	Capacité à payer les dettes immédiates

6.3 Exemple concret d'explication

Pour une entreprise analysée :

Score de base (entreprise moyenne) : 0.125

Résultat exploitation / Charges financières = 1105 → +4.39 points de risque

Chiffre d'affaires / Créances = 5 → -0.61 (facteur positif)

Score final : 6.109 → Faillite hautement probable

Le système justifie chaque point de son score.

7. L'application web

Toute l'intelligence artificielle a été encapsulée dans une application web accessible depuis n'importe quel navigateur. Pas besoin d'installer quoi que ce soit.

7.1 Comment utiliser l'application

- Ouvrir l'application dans un navigateur web
- Saisir les 10 ratios financiers de l'entreprise à analyser
- Cliquer sur « Analyser l'Entreprise »
- Lire les résultats en quelques secondes

7.2 Ce que l'application affiche

Élément affiché	Description	Exemple
Score de risque	Un pourcentage de 0% à 100%	75% = risque élevé
Niveau de risque	FAIBLE / MODÉRÉ / ÉLEVÉ	Code couleur vert/orange/rouge
Verdict	Entreprise saine ou Faillite probable	Décision claire
Graphique SHAP	Variables décisives visualisées	Explication visuelle
Tableau détaillé	Impact de chaque ratio sur le score	Analyse approfondie

7.3 Les seuils de risque

Probabilité	Niveau	Signification
0% — 39%	FAIBLE	Entreprise financièrement saine
40% — 69%	MODÉRÉ	Signaux d'alerte à surveiller
70% — 100%	ÉLEVÉ	Risque sérieux de faillite

8. Résultats finaux du projet

8.1 Performance du meilleur modèle — LightGBM

Métrique	Score	Ce que ça signifie
Précision globale	97.18%	Le système a raison 97 fois sur 100
Détection des faillites (Recall)	96.68%	Détecte presque toutes les faillites
Précision sur les faillites	97.67%	Très peu de fausses alertes
Score F1 global	97.17%	Équilibre parfait précision/recall
AUC-ROC	~0.99	Quasi-parfait (1.0 = parfait)

Sur 8 010 entreprises en faillite réelle dans les données de test, le système en a correctement identifié 7 755. Il n'en a raté que 255.

8.2 Comparaison avec la référence du marché

Fonctionnalité	Référence (Technocolabs)	Notre projet
Explication SHAP des décisions	Non	■ Oui
Application web fonctionnelle	Non (hors ligne)	■ Oui
Score de risque lisible	Non	■ Oui
Pipeline ML formalisé	Non	■ Oui
Baseline Altman Z-Score	Non	Prévu

9. Architecture du projet

9.1 Les outils utilisés

Outil	Rôle
Python	Langage de programmation principal
LightGBM	Le moteur d'intelligence artificielle
SHAP	Outil d'explication des décisions
Flask	Cadre de travail pour l'application web
Scikit-learn	Bibliothèque d'apprentissage automatique
Pandas / NumPy	Outils de manipulation des données
Matplotlib	Outil de visualisation graphique
Docker	Conteneurisation de l'application
GitHub Actions	Automatisation des tests et déploiement

9.2 Structure des fichiers du projet

```

corporate-bankruptcy-prediction/
├── app.py Le serveur web
├── models/
│   ├── lightgbm_best_model.pkl Le modèle sauvegardé
│   └── feature_names.pkl Les 10 variables
├── templates/
│   ├── index.html L'interface utilisateur
│   └── static/
│       ├── style.css Le design de l'application
│       └── notebooks/
│           ├── staelle.ipynb Le carnet de travail complet
│           └── requirements.txt La liste des outils nécessaires

```

10. Conclusion et perspectives

10.1 Ce qui a été accompli

- Collecte et nettoyage de données financières réelles de 43 405 entreprises
- Construction et comparaison de 6 modèles d'intelligence artificielle
- Atteinte d'une précision de 97% avec LightGBM
- Implémentation de l'explicabilité SHAP pour justifier chaque décision
- Développement d'une application web complète avec score de risque visuel
- Mise en place d'un pipeline de déploiement automatisé via GitHub Actions

10.2 Les limites du système

■■ Ce système est un outil d'aide à la décision, pas un oracle. Il est basé sur des données polonaises de 2000–2013. Les conditions économiques actuelles peuvent différer. Il doit être utilisé en complément d'une analyse humaine, pas en remplacement.

10.3 Améliorations futures envisagées

- Intégration du modèle Altman Z-Score comme référence classique
- Mise à jour avec des données plus récentes (post-2013)
- Extension à d'autres pays et secteurs d'activité
- Ajout d'une API REST pour intégration dans des systèmes tiers
- Interface multilingue (français, anglais, espagnol)

Projet réalisé dans le cadre d'un portfolio de Data Science

Polish Companies Bankruptcy Dataset — UCI Machine Learning Repository | Mai–Juin 2026